

Sistem preporuke – Turistička agencija

Razvoj softvera II – seminarski rad (IB210290, Mirnes Turković)

1. Opis

Aplikacija preporučuje putovanja klijentima pomoću **user-based collaborative filtering** algoritma (filtriranje zasnovano na korisnicima), kako je opisano u prijavi teme. Pretpostavka je da će se korisnici koji su se u prošlosti slagali u ocjenama putovanja vjerovatno slagati i u budućnosti.

Ulazni podaci su ocjene putovanja (tabela Ocjene, vrijednosti 1–5). Jedan korisnik može ocijeniti jedno putovanje samo jednom (jedinствени индекс KorisnikId + PutovanjeId; ponovno ocjenjivanje ažurira postojeću ocjenu).

2. Algoritam

Korak 1 – sličnost korisnika (Pearsonova korelacija). Za ciljnog korisnika a i svakog drugog korisnika b posmatraju se samo putovanja koja su **oba ocijenila** (skup P):

$$\text{sim}(a,b) = \frac{\sum_p (o(a,p) - \bar{o}(a)) \cdot (o(b,p) - \bar{o}(b))}{\sqrt{\sum_p (o(a,p) - \bar{o}(a))^2} \cdot \sqrt{\sum_p (o(b,p) - \bar{o}(b))^2}}$$

gdje su $\bar{o}(a)$ i $\bar{o}(b)$ prosjeci ocjena nad tim zajedničkim putovanjima. Ako je nazivnik 0 (korisnik je dao sve iste ocjene), sličnost je 0.

Korak 2 – K najbližih susjeda (KNN). Zadržavaju se korisnici sa pozitivnom sličnošću i najmanje 2 zajednički ocijenjena putovanja (da jedna slučajna zajednička ocjena ne da sličnost 1.0). Sortiraju se po sličnosti i uzima se K najsličnijih ($K = 5$).

Korak 3 – predviđanje ocjene. Za svako buduće putovanje koje korisnik nije ocijenio niti rezervisao:

$$\text{pred}(a,p) = \bar{o}(a) + \frac{\sum_n \text{sim}(a,n) \cdot (o(n,p) - \bar{o}(n))}{\sum_n |\text{sim}(a,n)|}$$

preko susjeda n koji su ocijenili p . Rezultat se ograničava na interval 1–5, a putovanja se sortiraju po predviđenoj ocjeni (preporučuju se ona sa predviđenom ocjenom ≥ 3).

Korak 4 – hladni start. Ako korisnik još nema ocjena ili nema dovoljno sličnih korisnika, lista se dopunjava najbolje ocijenjenim budućim putovanjima (izvor „Popularno”).

Provjera na primjeru sa predavanja

Primjer iz predavanja P9 / Excel fajla *Sistemi_Preporuke_Primjer 2.xlsx* (ocjene za BMW, Audi, VW, Mercedes, Hyundai):

Korisnik	Sličnost sa Zaninom	Zajedničkih ocjena
Jasmin	0,853	4
Goran	0,707	4
Adel	0,000	4
Denis	-0,792	4

Uz $K = 2$ (Jasmin, Goran): $\text{pred}(\text{Zanin, Hyundai}) = 4 + (0,853 \cdot (3 - 2,25) + 0,707 \cdot (5 - 3,5)) / (0,853 + 0,707) = 5,09 \rightarrow 5$. Vrijednosti su identične formulama iz Excel primjera (kolone *Sličnost* i *Predikcija N=2*). Na slajdu je za Jasmina navedeno 0,634, ali ista formula u Excel primjeru daje 0,853.

3. Parametri

Parametri nisu hardkodirani – nalaze se u konfiguraciji (`appsettings.json`, u Dockeru `.env`):

Parametar	Vrijednost	Značenje
Preporuke__BrojSusjeda	5	K u KNN
Preporuke__MinZajedničkihOcjena	2	minimalan broj zajednički ocijenjenih putovanja
Preporuke__MinSličnost	0	uzimaju se samo susjedi sa većom sličnošću
Preporuke__BrojPreporuka	5	broj preporučenih putovanja

4. Putanje do izvornog koda

- Algoritam (bez baze, lako testiranje):
`TuristickaAgencija.Services/RecommenderService/UserBasedCollaborativeFiltering.cs`
- Servis (učitavanje ocjena, kandidati, hladni start):
`TuristickaAgencija.Services/RecommenderService/RecommenderService.cs`
- API:
`TuristickaAgencija.WebAPI/Controllers/RecommenderController.cs`
 - `GET api/Recommender/Moje` – preporuke za prijavljenog korisnika (mobilna aplikacija)
 - `GET api/Recommender/GetRecommendedPutovanja/{putovanjeId}` – preporuke na detaljima putovanja (mobilna aplikacija)
 - `GET api/Recommender/Korisnik/{korisnikId}` – detaljan rezultat sa susjedima (desktop, samo Admin)

- Desktop prikaz:
UI/turisticka_agencija_admin/lib/screens/preporuke_screen.dart

Glavna logika – Pearsonova sličnost

```
public static (double Slicnost, int Zajednickih, double ProsjekA, double ProsjekB) PearsonSlicnost(
    IReadOnlyDictionary<int, double> a,
    IReadOnlyDictionary<int, double> b)
{
    var zajednicka = a.Keys.Where(b.ContainsKey).ToList();
    var n = zajednicka.Count;
    if (n == 0)
    {
        return (0, 0, 0, 0);
    }

    var prosjekA = zajednicka.Average(p => a[p]);
    var prosjekB = zajednicka.Average(p => b[p]);

    double brojnik = 0, sumaA = 0, sumaB = 0;
    foreach (var p in zajednicka)
    {
        var da = a[p] - prosjekA;
        var db = b[p] - prosjekB;
        brojnik += da * db;
        sumaA += da * da;
        sumaB += db * db;
    }

    var nazivnik = Math.Sqrt(sumaA) * Math.Sqrt(sumaB);
    if (nazivnik == 0)
    {
        // Neko od njih je dao sve iste ocjene -> korelacija nije definisana.
        return (0, n, prosjekA, prosjekB);
    }

    return (brojnik / nazivnik, n, prosjekA, prosjekB);
}
```

Pearsonova sličnost

Glavna logika – predviđanje ocjene

```
public static List<Predikcija> Predvidi(
    int korisnikId,
    IReadOnlyDictionary<int, Dictionary<int, double>> matrica,
    IReadOnlyCollection<Susjed> susjedi,
    IEnumerable<int> kandidati)
{
    var rezultat = new List<Predikcija>();
    if (!matrica.TryGetValue(korisnikId, out var ocjeneKorisnika) || ocjeneKorisnika.Count == 0 || susjedi.Count == 0)
    {
        return rezultat;
    }

    var prosjekKorisnika = ocjeneKorisnika.Values.Average();

    foreach (var putovanjeId in kandidati.Distinct())
    {
        if (ocjeneKorisnika.ContainsKey(putovanjeId))
        {
            continue; // vec ocijenjeno -> nema smisla preporucivati
        }

        double brojnik = 0, nazivnik = 0;
        var broj = 0;
        foreach (var susjed in susjedi)
        {
            if (!matrica[susjed.KorisnikId].TryGetValue(putovanjeId, out var ocjenaSusjeda))
            {
                continue;
            }

            brojnik += susjed.Slicnost * (ocjenaSusjeda - susjed.ProsjekSusjeda);
            nazivnik += Math.Abs(susjed.Slicnost);
            broj++;
        }

        if (broj == 0 || nazivnik == 0)
        {
            continue;
        }

        var predikcija = Math.Clamp(prosjekKorisnika + brojnik / nazivnik, 1, 5);
        rezultat.Add(new Predikcija
        {
            PutovanjeId = putovanjeId,
            PredvidjenaOcjena = Math.Round(predikcija, 2),
            BrojSusjeda = broj
        });
    }

    return rezultat
        .OrderByDescending(x => x.PredvidjenaOcjena)
        .ThenByDescending(x => x.BrojSusjeda)
        .ToList();
}
```

Predviđanje ocjene

5. Prikaz u aplikaciji

Desktop aplikacija – Preporuke – odabrali klijenta „Amila Turković (mobile)“.

Prikazuju se najbliži klijenti (Pearsonova sličnost i broj zajedničkih ocjena) i preporučena putovanja sa predviđenom ocjenom.

Sa testnim podacima korisnik *mobile* voli ljetovanja (Budva 5, Dubrovnik 5) a slabije ocjenjuje gradske ture (Beograd 2, Minhen 2, Beč 2). Algoritam pronalazi klijente sličnog ukusa i preporučuje:

Putovanje	Predviđena ocjena	Broj susjeda koji su ga ocijenili
Split i Hvar	4,51	4
Madrid i Toledo	4,46	1
Atina i Akropolj	4,46	1
Barcelona i Costa Brava	4,42	4
Santorini – grčka bajka	4,33	3

(Ovdje dodati screenshot ekrana „Preporuke” iz desktop aplikacije i ekrana sa preporukama iz mobilne aplikacije.)